UNIVERSIDADE FEDERAL DE ITAJUBÁ - UNIFEI

CAMPUS POUSO ALEGRE

PLANO DE TRABALHO · BLOCO 1 DE 6

Fundamentos de programação, Machine Learning e ECG

Aplicativo móvel para triagem experimental de fibrilação atrial por ECG de uma derivação com Inteligência Artificial confiável

Período de execução	novembro/2026 a abril/2027
Meses do projeto	M1–M6
Curso	Engenharia de Software
Orientação	Prof. Dr. Rafael Sanchotene Silva

Uso acadêmico e experimental. O aplicativo não é um dispositivo médico e não substitui avaliação clínica.

Objetivo dos próximos 6 meses

Construir a base técnica e científica necessária para que o aluno consiga trabalhar de forma autônoma com Python, Git, dados biomédicos e um primeiro pipeline de Machine Learning, terminando o semestre com uma análise exploratória reproduzível de ECG.

Competências esperadas ao final do bloco

- Programar em Python com organização básica de projeto e ambientes virtuais.
- Usar Git/GitHub para versionar exercícios, notebooks e documentação.
- Manipular dados com NumPy/pandas e produzir visualizações simples.
- Explicar o fluxo preparação → treinamento → avaliação de um modelo de ML.
- Reconhecer conceitos básicos de ECG, fibrilação atrial, ruído e qualidade de sinal.
- Acessar uma base pública via PhysioNet/WFDB e produzir um dataset card inicial.

Focos do período

- Curso de Python (M1–M3)
- Curso de Machine Learning (M4–M6)
- Leitura científica orientada
- PhysioNet/WFDB e análise exploratória de ECG

Cursos obrigatórios deste bloco

Curso de Python — M1 a M3

Playlist: abrir Curso de Python

Evidência: repositório de exercícios + mini-projeto reprodutível.

Curso de Machine Learning — M4 a M6

Playlist: abrir Curso de Machine Learning

Evidência: exercícios versionados + notebook final cobrindo preparação de dados, treinamento e avaliação.

Plano mensal

Mês	Atividade principal	Entregável verificável
M1 nov/2026	Integração ao projeto; revisar o artigo já lido; criar ficha crítica de 2 páginas; instalar Python, Git e VS Code; iniciar o Curso de Python.	Ficha de leitura + repositório criado.
M2 dez/2026	Curso de Python; exercícios de variáveis, estruturas, funções e arquivos; Git básico; padronizar estrutura de pastas.	20–30 exercícios versionados.
M3 jan/2027	Concluir o Curso de Python; NumPy, pandas e matplotlib; mini-projeto com CSV; ambientes virtuais.	Mini-projeto Python reprodutível.
M4 fev/2027	Iniciar o Curso de Machine Learning; fundamentos de ECG e fibrilação atrial; leitura orientada de 4–6 trabalhos recentes; iniciar matriz bibliográfica.	Matriz de literatura v1 + exercícios iniciais de ML.
M5 mar/2027	Prosseguir no Curso de Machine Learning; aprender PhysioNet/WFDB; obter amostra da base; documentar licença, rótulos, indivíduos, taxa de amostragem e classes.	Dataset card v1 + exercícios de ML versionados.
M6 abr/2027	Concluir o Curso de Machine Learning; produzir notebook final do curso; realizar análise exploratória dos ECGs, incluindo duração, classes, ruído e qualidade; seminário interno.	Notebook final de ML + notebook EDA + seminário S1.

Marco semestral

Ao final do bloco, o aluno deverá demonstrar o repositório, executar o notebook final do curso de ML, apresentar a EDA da base de ECG e explicar, em 10–15 minutos, o problema de classificação proposto e seus principais riscos metodológicos.

Checklist de encerramento do bloco

- ☐ Repositório Git organizado e atualizado.
- ☐ Curso de Python concluído com mini-projeto.
- ☐ Curso de Machine Learning concluído com notebook final.
- ☐ Matriz bibliográfica e dataset card v1.
- ☐ EDA de ECG executável do início ao fim.
- ☐ Seminário S1 realizado.

Acompanhamento

- Reunião quinzenal curta: atividades concluídas, evidências, dificuldades e próxima tarefa.
- Relatório mensal de até 1 página com links para commits, notebooks, testes, tabelas ou versões do aplicativo.
- Seminário ao final do bloco com demonstração de pelo menos um artefato executável.
- Avanço para a etapa seguinte condicionado à reprodutibilidade e à compreensão das decisões metodológicas.

Regra para avançar ao próximo bloco

Somente avançar para comparação de classificadores se o repositório puder ser reproduzido em ambiente limpo e se a divisão dos dados estiver claramente documentada.

Limite de uso

Todo resultado deve ser apresentado como classificação experimental. O aplicativo não deve fornecer diagnóstico, prescrição ou recomendação clínica. Sinais anormais ou inconclusivos exigem confirmação por procedimento clínico apropriado.